

6. PRUEBA DE CONCEPTO (PoC)

Sistema Multiagente para la Priorización de Proyectos de Inversión en la Municipalidad Distrital de El Tambo

Integrantes: Carhuamaca Vasquez, Diego; Chuchon Sotelo, Ernesto; Huachos Lopez, Madelyn; Reinaga Cisneros, Hermiluz; Sierra Leiva, Piero Martin.

La PoC valida la viabilidad técnica del componente de recuperación RAG asociado a la Épica 2 - Consulta Automatizada de Normativa (RAG Agéntico), antes de integrarlo al PMV1. Se documenta la trazabilidad con las historias de usuario, el dataset, la preparación de datos, el código ejecutado, las métricas obtenidas, las limitaciones y la decisión Go/No-Go.

1. Requerimiento con IA y trazabilidad

Elemento	Definición
Épica e historias de usuario	Épica 2 - Consulta Automatizada de Normativa (RAG Agéntico). HU2.1: búsqueda automática de normativa (validada directamente). HU2.2: cita del artículo exacto (pendiente de validación completa con normativa oficial). HU2.3: Alerta Legal (demostrada parcialmente con metadatos simulados).
Requerimientos asociados	RF07 - Recuperación Híbrida de Información; brinda soporte a RF05 - Auditoría Jurídica y Normativa.
PMV asociado	PMV1: incluye Agente Jurídico y RAG agéntico básico sobre normativa.
Incertidumbre técnica	¿El RAG híbrido puede recuperar el fragmento normativo esperado con suficiente relevancia y baja latencia?
Objetivo	Comprobar técnicamente el mecanismo de recuperación de HU2.1/RF07 y demostrar de forma preliminar el flujo de alerta de HU2.3 antes de incorporarlo al PMV1.
Tecnologías	Python, Google Colab, SentenceTransformers, Qdrant en memoria para recuperación densa, BM25 ejecutado en Python y Reciprocal Rank Fusion (RRF).

2. Hipótesis y criterio de éxito

Hipótesis H1: una configuración de embeddings combinada con recuperación densa, BM25 y RRF puede recuperar el fragmento esperado dentro de los tres primeros resultados en al menos el 94 % de las consultas etiquetadas. En esta PoC, el criterio de precisión/relevancia ≥ 94 % se operacionaliza específicamente mediante la métrica Hit@3.

Métrica	Interpretación	Criterio
Hit@3	El fragmento esperado aparece dentro de los 3 primeros resultados.	≥ 94 % (métrica principal)
Accuracy@1	El fragmento esperado aparece en la primera posición.	Métrica secundaria
MRR	Valora qué tan arriba aparece el primer resultado correcto.	Métrica secundaria
Latencia	Tiempo promedio de recuperación por consulta.	Comparación de eficiencia

3. Dataset y preparación de datos

El dataset principal es base_normativa_simulada_poc.csv. Fue generado para probar el funcionamiento técnico del RAG sin usar expedientes reales ni datos personales. Su contenido es didáctico y simulado: representa cuatro grupos normativos del proyecto, pero no reproduce artículos oficiales ni debe utilizarse para emitir un dictamen legal.

Característica	Descripción
Tamaño	24 registros (fragmentos normativos resumidos).
Grupos normativos representados	Resúmenes didácticos simulados de: Ley N.º 27972; D. L. N.º 1252 - Invierte.pe; Ley N.º 32069; y PDU/PDM Huancayo-El Tambo. No son transcripciones de artículos oficiales.
Distribución	6 registros por cada grupo normativo.
Variables	id, documento, tema, contenido, alerta.
Datos faltantes	0 valores faltantes en la base generada.
Campo alerta	22 registros False y 2 True. Es metadato de demostración; no se usa como clase de entrenamiento.
Conjunto de evaluación	30 consultas etiquetadas con un id_esperado para medir la recuperación.

Significado de las variables:

Campo	Función
id	Identificador único del fragmento, por ejemplo PDUPDM-02.

Campo	Función
documento	Grupo normativo que el fragmento representa.
tema	Tema jurídico o territorial asociado.
contenido	Resumen didáctico utilizado para generar el embedding y realizar la búsqueda.
alerta	Indicador simulado usado en la demostración de una posible Alerta Legal.

Preparación del dataset y del modelo: no se entrenó ni se hizo fine-tuning de BGE-M3 o Qwen3; ambos son modelos preentrenados. La PoC realizó inferencia zero-shot. Se cargaron los 24 textos, se generaron embeddings normalizados y Qdrant almacenó y consultó los vectores densos mediante similitud coseno. En paralelo, BM25 se ejecutó externamente en Python para la coincidencia léxica. Finalmente, ambos rankings se fusionaron mediante Reciprocal Rank Fusion (RRF) y se ejecutaron las 30 consultas etiquetadas para comparar el Top-3 recuperado con el id esperado.

4. Modelos evaluados y prototipo mínimo

Experimento	Modelo	Configuración
E1	BAAI/bge-m3	Embeddings normalizados + Qdrant (búsqueda densa) + BM25 externo en Python + RRF.
E2	Qwen/Qwen3-Embedding-0.6B	Embeddings normalizados + Qdrant (búsqueda densa) + BM25 externo en Python + RRF.

Flujo de la PoC:

24 resúmenes simulados → embeddings densos / BM25 → Qdrant + búsqueda léxica en Python → RRF → Top-3 → métricas → Go/No-Go

5. Experimentación, resultados y evidencia

Cada modelo respondió las mismas 30 consultas. Para cada consulta se verificó si el identificador esperado aparecía en la primera posición y dentro del Top-3. También se registró la posición recíproca y el tiempo de recuperación.

Modelo	Accuracy@1	Hit@3	MRR	Latencia prom.	Cumple
BGE-M3	90.00 %	100.00 %	0.944	0.031 s	Sí
Qwen3-Embedding-0.6B	96.67 %	100.00 %	0.983	0.071 s	Sí

Interpretación: ambos modelos alcanzaron Hit@3 = 100 %, por encima del 94 % requerido. Qwen3-Embedding-0.6B obtuvo mejor Accuracy@1 (96,67 %) y MRR (0,983), mientras que BGE-M3 presentó menor latencia promedio (0,031 s frente a 0,071 s). Por tanto, Qwen3 ofrece mejor calidad de ranking y BGE-M3 mayor velocidad. El script mostró BGE-M3 como “mejor modelo” únicamente porque ordenó por Hit@3 y ambos empataron en 100 %; esa salida automática no constituye por sí sola el criterio definitivo de selección para el PMV1.

5.1 Análisis detallado por consulta

El análisis de los archivos de detalle muestra que BGE-M3 ubicó el fragmento esperado en la primera posición en 27 de 30 consultas, mientras que Qwen3 lo hizo en 29 de 30. En todas las consultas, para ambos modelos, el fragmento esperado estuvo dentro del Top-3.

Indicador	BGE-M3	Qwen3-Embedding-0.6B
Aciertos en Top-1	27/30 (90,00 %)	29/30 (96,67 %)
Desviaciones Top-1	3/30	1/30
Aciertos en Top-3	30/30 (100 %)	30/30 (100 %)

Los casos donde el identificador esperado no apareció en primer lugar no implican necesariamente que el primer resultado fuera irrelevante: varios pertenecen a temas normativos semánticamente cercanos. No obstante, son evidencia de que el ranking debe validarse nuevamente cuando se utilice un corpus oficial y más amplio.

Modelo	Consulta	Esperado	Top-1	Pos. esperada
BGE-M3	¿Qué fuente debería consultar para funciones municipales sobre desarr...	LEY27972-02	PDUPDM-06	2
BGE-M3	¿Qué fuente relaciona las inversiones con el cierre de brechas?	DL1252-04	DL1252-01	2
BGE-M3	¿Qué instrumento permite identificar la zonificación urbana de un área?	PDUPDM-01	PDUPDM-02	3
Qwen3	¿Qué instrumento permite identificar la zonificación urbana de un área?	PDUPDM-01	PDUPDM-02	2

```
[11]
✓ 0s
mejor = resumen_df.sort_values("Hit@3", ascending=False).iloc[0]
hit = float(mejor["Hit@3"])

if hit >= 0.94:
    decision = "GO"
elif hit >= 0.85:
    decision = "GO CON CONDICIONES"
else:
    decision = "NO-GO"

print("==== RESULTADO FINAL DE LA PoC =====")
print("Mejor modelo:", mejor["Modelo"])
print(f"Accuracy@1: {mejor['Accuracy@1']:.2%}")
print(f"Hit@3: {mejor['Hit@3']:.2%}")
print(f"MRR: {mejor['MRR']:.3f}")
print(f"Latencia: {mejor['Latencia_promedio_s']:.3f} s")
print("DECISIÓN:", decision)

resumen_df.to_csv("resultados_resumen_poc.csv", index=False, encoding="utf-8-sig")

for nombre, detalle in resultados_detalle.items():
    safe = re.sub(r"[^A-Za-z0-9_-]+", "_", nombre)
    detalle.to_csv(f"detalle_{safe}.csv", index=False, encoding="utf-8-sig")

print("\nArchivos generados:")
print("- resultados_resumen_poc.csv")
print("- detalle_<modelo>.csv")

***
==== RESULTADO FINAL DE LA PoC =====
Mejor modelo: BGE-M3
Accuracy@1: 90.00%
Hit@3: 100.00%
MRR: 0.944
Latencia: 0.031 s
DECISIÓN: GO

Archivos generados:
- resultados_resumen_poc.csv
- detalle_<modelo>.csv
```

Figura 1. Resultado final real de la PoC en Google Colab: métricas y decisión GO.

6. Limitaciones

Limitación	Impacto	Acción
Dataset simulado	Valida el pipeline, pero no la exactitud jurídica de un corpus real.	Repetir con textos oficiales y vigentes.
24 fragmentos	Volumen pequeño frente a un repositorio municipal real.	Ampliar corpus y consultas en PMV1.
30 consultas creadas para la PoC	La evaluación es controlada y puede favorecer temas presentes en la base.	Incorporar preguntas independientes y casos de mayor dificultad.
Sin entrenamiento/fine-tuning	Se evalúan modelos preentrenados tal como fueron publicados.	Ajustar solo si el corpus real lo requiere.
Normativa dinámica	Un documento desactualizado puede producir evidencia incorrecta.	Registrar versión, fecha y fuente oficial.

7. Decisión Go / No-Go

Decisión: GO para el mecanismo de recuperación evaluado (HU2.1 / RF07). La hipótesis se acepta para el alcance de esta PoC porque ambos modelos alcanzaron Hit@3 = 100 %, superando la meta de 94 %. La prueba demuestra viabilidad técnica del retrieval híbrido para continuar hacia el PMV1. No implica que toda la Épica 2 esté validada: HU2.2 requiere artículos y citas oficiales, y HU2.3 debe repetirse con normativa real y revisión jurídica humana.

8. Recomendación para PMV1

Para el PMV1 se recomienda utilizar Qwen3-Embedding-0.6B como modelo inicial de embeddings, porque mantuvo Hit@3 = 100 % y obtuvo mejor Accuracy@1 (96,67 %) y MRR (0,983), indicadores relevantes para colocar la evidencia correcta en las primeras posiciones. BGE-M3 se conserva como alternativa de menor latencia. La selección deberá revalidarse con un corpus de normativa oficial vigente, conservando metadatos de documento, versión, artículo/sección, fecha y fuente, y manteniendo revisión humana antes de cualquier conclusión jurídica.

ANEXO A. Evidencia del código Python

El profesor solicitó centralizar en el documento la evidencia del programa Python. A continuación se muestran extractos del mismo código utilizado en la notebook de Google Colab. El código completo corresponde a la notebook de la PoC.

Evidencia A1 - creación del dataset

```
1 records = [...] # 24 fragmentos normativos simulados
2
3 df = pd.DataFrame(
4     records,
5     columns=["id", "documento", "tema", "contenido", "alerta"]
6 )
7
8 print("Fragmentos:", len(df))
9 df.to_csv("base_normativa_simulada_poc.csv", index=False, encoding="utf-8-sig")
```

Figura A1. Creación del dataset de 24 fragmentos y exportación CSV.

Evidencia A2 - embeddings e indexación Qdrant

```
1 MODELOS_LOCALES = {
2     "BGE-M3": "BAAI/bge-m3",
3     "Qwen3-Embedding-0.6B": "Qwen/Qwen3-Embedding-0.6B",
4 }
5
6 def crear_indice_qdrant(modelo, nombre_modelo):
7     embeddings = modelo.encode(
8         df["contenido"].tolist(),
9         normalize_embeddings=True
10    )
11    client = QdrantClient(":memory:")
12    # colección con distancia coseno
13    # se insertan los 24 vectores y sus metadatos
14    return client
```

Figura A2. Carga de modelos, generación de embeddings e indexación en Qdrant.

Evidencia A3 - búsqueda híbrida y evaluación

```
1 def buscar_hibrido(client, modelo, consulta, top_k=5):
2     dense = buscar_semantico(client, modelo, consulta, top_k=10)
3     lexical = buscar_bm25(consulta, top_k=10)
4     # Reciprocal Rank Fusion (RRF) para unir ambos rankings
5     ...
6     return resultados[:top_k]
7
8 def evaluar_modelo(nombre, modelo, client):
9     # 30 consultas con id_esperado
10    # calcula Accuracy@1, Hit@3, MRR y latencia
11    ...
```

Figura A3. Recuperación híbrida y evaluación de las 30 consultas.

Evidencia A4 - regla de decisión

```
1  if hit >= 0.94:
2      decision = "GO"
3  elif hit >= 0.85:
4      decision = "GO CON CONDICIONES"
5  else:
6      decision = "NO-GO"
7
8  print("Mejor modelo:", mejor["Modelo"])
9  print(f"Accuracy@1: {mejor['Accuracy@1']:.2%}")
10 print(f"Hit@3: {mejor['Hit@3']:.2%}")
11 print(f"MRR: {mejor['MRR']:.3f}")
12 print("DECISIÓN:", decision)
```

Figura A4. Regla automática de decisión GO / GO CON CONDICIONES / NO-GO.

ANEXO B. Evidencias reales de ejecución en Google Colab

Las siguientes capturas corresponden a la ejecución real de la notebook. Se muestran la generación del dataset, el conjunto de 30 consultas, la comparación de modelos, una consulta demostrativa del Agente Jurídico y la decisión final.




Figura B1. Generación del dataset: 24 fragmentos y exportación del CSV.




Figura B2. Conjunto de evaluación: 30 consultas etiquetadas con id_esperado.




Figura B3. Comparación real de BGE-M3 y Qwen3: métricas y latencia.




Figura B4. Demostración de la Épica 2: recuperación de evidencia y ejemplo de Alerta Legal con revisión humana.

```

[11]
✓ 0s
mejor = resumen_df.sort_values("Hit@3", ascending=False).iloc[0]
hit = float(mejor["Hit@3"])

if hit >= 0.94:
    decision = "GO"
elif hit >= 0.85:
    decision = "GO CON CONDICIONES"
else:
    decision = "NO-GO"

print("==== RESULTADO FINAL DE LA PoC =====")
print("Mejor modelo:", mejor["Modelo"])
print(f"Accuracy@1: {mejor['Accuracy@1']:.2%}")
print(f"Hit@3: {mejor['Hit@3']:.2%}")
print(f"MRR: {mejor['MRR']:.3f}")
print(f"Latencia: {mejor['Latencia_promedio_s']:.3f} s")
print("DECISIÓN:", decision)

resumen_df.to_csv("resultados_resumen_poc.csv", index=False, encoding="utf-8-sig")

for nombre, detalle in resultados_detalle.items():
    safe = re.sub(r"^[^A-Za-z0-9_-]+", "_", nombre)
    detalle.to_csv(f"detalle_{safe}.csv", index=False, encoding="utf-8-sig")

print("\nArchivos generados:")
print("- resultados_resumen_poc.csv")
print("- detalle_<modelo>.csv")

...
==== RESULTADO FINAL DE LA PoC =====
Mejor modelo: BGE-M3
Accuracy@1: 90.00%
Hit@3: 100.00%
MRR: 0.944
Latencia: 0.031 s
DECISIÓN: GO

Archivos generados:
- resultados_resumen_poc.csv
- detalle_<modelo>.csv

```

Figura B5. Regla de decisión y resultado final GO.

ANEXO C. Evidencia del dataset y archivos de resultados

Ejemplo	Documento	Tema	Alerta
LEY27972-01	Ley N.º 27972	Competencias municipales	No
DL1252-04	D. L. N.º 1252	Cierre de brechas	No
LEY32069-06	Ley N.º 32069	Transparencia y trazabilidad	No
PDUPDM-02	PDU/PDM Huancayo-El Tambo	Compatibilidad de uso de suelo	Sí
PDUPDM-04	PDU/PDM Huancayo-El Tambo	Zonas de riesgo	Sí

Modelo	Top-1 correctos	Top-1 no esperado	Top-3 correctos	Conclusión
BGE-M3	27/30	3/30	30/30	Cumple
Qwen3-Embedding-0.6B	29/30	1/30	30/30	Cumple

Archivos generados y conservados como evidencia reproducible: base_normativa_simulada_poc.csv (24 fragmentos), resultados_resumen_poc.csv (comparación agregada), detalle_BGE-M3.csv y detalle_Qwen3-Embedding-0.6B.csv (resultado individual de las 30 consultas por modelo).

ANEXO D. Enlace de Google Colab

Enlace compartible de la notebook: <https://colab.research.google.com/drive/1ugRM6ubjQY82bpj9B7Z5rNRt7WWGXwhQ?usp=sharing>

Nota: el enlace corresponde a la notebook de Google Colab utilizada para ejecutar la PoC y centraliza el código completo que respalda las capturas y archivos de resultados incluidos en los anexos.